

28. Latent Factor Models

항목	ICA	PCA	FA
목적	독립된 성분 찾기	최대한 많은 분산 설명	공통 요인 구조 학습
잠재 변수 zz	통계적으로 독립	직교(orthogonal)	선형 + 노이즈 포함
노이즈	없음 (또는 매우 작게 가정)	없음	명시적으로 포함
통계적 가정	비가우시안, 독립	가우시안, 직교	가우시안, 노이즈 있음
복원 가능성	스케일·순서 불변	고유값 크기 순 정렬	label ambiguity 존재

다음처럼 관측 데이터를 생성하는 메커니즘에 대해 확률적 모델을 세운다

27 Discovery methods: an overview

- if our goal is
 - understand a given dataset
 - discover something “interesting”, and possibly “actionable”
 - Prediction and generation are useful subroutines for discovery, but are not sufficient..
- 우리가 시각적으로 무언가를 보는 행위에 비유해서 설명하자면..
 - 시각적으로 보는 행위(vision)는
 - ⇒ 실제 세계의 hidden state로부터 관측 가능한 이미지(visible state)가 생성되는 과정을 역추론(infer)하는 작업




Figure 27.1: Vision as inverse graphics. The agent (here represented by a human head) has to infer the scene z given the image x using an estimator. From Figure 1 of [Rao99]. Used with kind permission of Rajesh Rao.

- (원) The World
 - hidden state : 눈으로 직접 볼 수 없는 세상의 내부 상태 z
 - visible state : 우리가 눈으로 보는 이미지 x
- (오) The Estimator
 - 인간의 시각 시스템
 - model: 세상에 대한 내부 모델
 - parameters: 모델을 구성하는 파라미터들 (ex. 위치, 크기, 조명)

- hidden state ("Internal" to the Estimator): 우리가 머릿속으로 추정해내야 하는 세상의 숨겨진 상태 z
- **inverse mapping**
 - 입력된 이미지 x 로부터 z 를 추정해내는 역함수
 - 이게 바로 우리가 이미지를 보고 이해하는 과정

- **So in this part of the book,**

- we focus on learning models that create an interpretable representation of high dimensional data
- A common approach : use a **latent variable model**

28 Latent factor models

28.1 Introduction

- latent variable model (LVM) : 일부 변수가 항상 잠재적(latent) 또는 숨겨져 있는 확률 모델
 - we make the assumption that the observed data x was caused / generated by, some latent factors z , which represents the "true" state of the world.
 - (예시) Mixture Model, HMM (Hidden Markov Model), VAE (Variational Autoencoder)
- (simple example) mixture model
 - z
 - 어떤 mixture component를 사용할지를 지정하는 지시 변수
 - 하나의 hidden random variable layer라고 가정
 - 잠재 요인(latent factors)
 - latent factor models !
 - LVM 중에서도, 데이터가 소수의 연속적인 잠재 요인(latent factors)에 의해 선형적으로 설명된다고 가정하는 모델

$$p(x) = \sum_k p(x \mid z = k)p(z = k)$$

- $p(z = k)$
 - $z \sim p(z)$
 - $p(z)$: 잠재 변수 z 에 대한 사전 확률 분포(prior)
- $p(x \mid z = k)$
 - $x \mid z \sim \text{Expfam}(x \mid f(z))$
 - $f(z)$: decoder
- 이 장에서는 decoder f 가 linear model이라고 가정
- 사전분포($p(x)$)와 likelihood $p(x|z)$ 를 바꿔서 다양한 classic models 만들 수 있음

Model	$p(\mathbf{z})$	$p(\mathbf{x} \mathbf{z})$	Section
FA/PCA	$\mathcal{N}(\mathbf{z} \mathbf{0}, \mathbf{I})$	$\mathcal{N}(\mathbf{x} \mathbf{W}\mathbf{z}, \mathbf{\Psi})$	Section 28.3.1
GMM	$\sum_c \text{Cat}(c \boldsymbol{\pi})\mathcal{N}(\mathbf{z} \boldsymbol{\mu}_c, \boldsymbol{\Sigma}_c)$	$\mathcal{N}(\mathbf{x} \mathbf{W}\mathbf{z}, \mathbf{\Psi})$	Section 28.2.4
MixFA	$\text{Cat}(c \boldsymbol{\pi})\mathcal{N}(\mathbf{z} \mathbf{0}, \mathbf{I})$	$\mathcal{N}(\mathbf{x} \mathbf{W}_c\mathbf{z} + \boldsymbol{\mu}_c, \mathbf{\Psi}_c)$	Section 28.3.3.5
NMF	$\prod_k \text{Ga}(z_k \alpha_k, \beta_k)$	$\prod_d \text{Poi}(x_d \exp(\mathbf{w}_d^\top \mathbf{z}))$	Section 28.4.1
Simplex FA (mPCA)	$\text{Dir}(\mathbf{z} \boldsymbol{\alpha})$	$\prod_d \text{Cat}(x_d \mathbf{W}_d\mathbf{z})$	Section 28.4.2
LDA	$\text{Dir}(\mathbf{z} \boldsymbol{\alpha})$	$\prod_d \text{Cat}(x_d \mathbf{W}\mathbf{z})$	Section 28.5
ICA	$\prod_d \text{Laplace}(z_d \lambda)$	$\prod_d \delta(x_d - \mathbf{w}_d^\top \mathbf{z})$	Section 28.6
Sparse coding	$\prod_k \text{Laplace}(z_k \lambda)$	$\prod_d \mathcal{N}(x_d \mathbf{w}_d^\top \mathbf{z}, \sigma^2)$	Section 28.6.5

Table 28.1: Some popular “shallow” latent factor models. Abbreviations: FA = factor analysis, PCA = principal components analysis, GMM = Gaussian mixture model, NMF = non-negative matrix factorization, mPCA = multinomial PCA, LDA = latent Dirichlet allocation, ICA = independent components analysis. $k = 1 : L$ ranges over latent dimensions, $d = 1 : D$ ranges over observed dimensions. (For ICA, we have the constraint that $L = D$.)

28.2 Mixture models

- Mixture models

- 복잡한 확률 모델을 만드는 하나의 방법 : take a convex combination of simple distributions
⇒ 이걸 Mixture model이라고 부름

$$p(x|\theta) = \sum_{k=1}^K \pi_k p_k(x)$$

- notation

- π_k : k번째 mixture weight(satisfy $0 \leq \pi_k \leq 1, \sum_{k=1}^K \pi_k = 1$)
즉, 분포가 선택될 확률
- $p_k(x)$: k번째 분포

- convex combination이어야 하는 이유

- mixture model도 확률 분포의 정의(비음수성&전체확률합 1)를 만족해야 하는데, 이미 $p_k(x)$ 는 확률분포니까 π_k 에 대한 조건 발생
- $0 \leq \pi_k \leq 1, \sum_{k=1}^K \pi_k = 1$

- Re-express as a hierarchical model

- 1) $z \sim \text{Cat}(\pi)$

- 잠재변수 z : output x 를 생성하는데에 어떤 분포를 사용할 것인가

discrete latent variable $z \in \{1, \dots, K\}$

- prior on z : 분포 선택

$$p(z|\theta) = \text{Cat}(z|\pi), p(z = k) = \pi_k$$

- 2) $x \sim p(x|\theta_z)$

$$p(x|z = k) = p_k(x) = p(x|\theta_k)$$

- joint model

$$p(x, z|\theta) = p(z|\theta) \cdot p(x|z, \theta)$$

$$p(x, z = k|\theta) = \pi_k \cdot p(x|\theta_k)$$

- z 는 우리가 모르는 변수니까, marginalizing out z

$$p(x | \theta) = \sum_{k=1}^K p(z = k | \theta) \cdot p(x | z = k, \theta) = \sum_{k=1}^K \pi_k \cdot p(x | \theta_k)$$

→ mixture model

→ p_k 를 어떻게 선택하느냐에 따라 다양한 mixture model이 나온다

- Latent Factor Model은 존재하는 데이터로부터 무언가를 “발견”하려는 접근인데, 이를 generative story를 이용하여 설명하는 이유
 - 데이터가 어떻게 만들어졌다고 가정함으로써, 그 속에서 latent factor를 발견하겠다

28.2.1 Gaussian Mixture models

여러 개의 가우시안 분포 mixture

$$p(x) = \sum_{k=1}^K \pi_k \cdot N(x | \mu_k, \Sigma_k)$$

- K 값이 커진다면 이론적으로
 - GMM can approximate any smooth distribution over R^D




Figure 28.1: A mixture of 3 Gaussians in 2d. (a) We show the contours of constant probability for each component in the mixture. (b) A surface plot of the overall density. Adapted from Figure 2.23 of [Bis06]. Generated by [gmm_plot_demo.ipynb](#).

2차원 공간에 있는 3개의 가우시안 분포로 구성된 GMM의 밀도 함수

- clustering에서 자주 사용됨
 - work with two-stage
 - (1) model fitting

$$MLE \hat{\theta} = \operatorname{argmax} \log p(D | \theta)$$

- $D = \{x_n : n = 1 : N\}$, θ : 모든 모델 파라미터

(2) cluster 찾기

- 각 데이터 x_n 은 어느 클러스터에서 생성되었는지 알려주는 잠재 변수 z_n 을 갖는다
 - $z_n \in \{1, \dots, K\}$
 - z_n 은 우리가 알 수 없지만, Bayes 정리를 통해 추론할 수 있다

- Responsibility r_{nk} of cluster k for datapoint n
 - 데이터 x_n 이 주어졌을 때, k번째 가우시안에서 나왔을 확률

$$r_{nk} \triangleq \frac{p(z_n = k | \mathbf{x}_n, \boldsymbol{\theta})}{\sum_{k'=1}^K p(z_n = k' | \boldsymbol{\theta}) p(\mathbf{x}_n | z_n = k', \boldsymbol{\theta})}$$

- notation
 - $p(\mathbf{x}_n | z_n = k, \boldsymbol{\theta})$: Likelihood, 클러스터 k에 속한다면 이 x_n 이 나올 확률"
 - $p(z_n = k | \boldsymbol{\theta})$: Prior, 클러스터 k가 선택될 확률 = 혼합 가중치 π_k

- most probable cluster assignment

$$\hat{z}_n = \arg \max_k r_{nk} = \arg \max_k [\log p(\mathbf{x}_n | z_n = k, \theta) + \log p(z_n = k | \theta)]$$

- basis of the K-means clustering algorithm
 - if uniform prior over z_n & spherical Gaussians with $\sum_k = I$
 - hard clustering problem reduces to

$$z_n = \arg \min_k \|x_n - \mu_k\|_2^2$$

- $\log p(z_n = k) \rightarrow \text{constant}$
- $p(x_n | z_n = k) = \mathcal{N}(x_n | \mu_k, I)$ 다변량 정규분포 확률밀도함수 수식으로 전개

$$\log \mathcal{N}(x_n | \mu_k, I) = -\frac{1}{2} \|x_n - \mu_k\|_2^2 + \text{constant}$$
- assign each datapoint to its closest centroid, as measured by Euclidean distance

28.2.2 Bernoulli mixture models

여러 개의 베르누이 분포의 곱으로 구성된 mixture model

- Binary 데이터를 모델링할 때 사용하는 혼합 모델(GMM은 연속적인 데이터를 위한 것)

$$p(x | z = k, \theta) = \prod_{d=1}^D \text{Ber}(y_d | \mu_{dk}) = \prod_{d=1}^D \mu_{dk}^{y_d} (1 - \mu_{dk})^{1-y_d}$$

- notation
 - μ_{dk} : probability that bit d turns on in cluster k
k번째 cluster에서 d번째 픽셀이 1일 확률
- 예시) MNIST dataset
 - fitting a mixture of Bernoullis using K=20 components
 - 각 이미지를 $\mathbf{x}_n \in \{0, 1\}^{784} \rightarrow$ 베르누이
 - resulting parameters for each mixture component




Figure 28.3: We fit a mixture of 20 Bernoullis to the binarized MNIST digit data. We visualize the estimated cluster means $\hat{\mu}_k$. The numbers on top of each image represent the estimated mixing weights $\hat{\pi}_k$. No labels were used when training the model. Generated by [mix_bernoulli_em_mnist.ipynb](#).

발견한 20개의 숫자 모양

- 비지도학습이었음에도, 숫자들의 패턴을 clustering을 통해 “discovery”했다

28.2.6 Unidentifiability

- label switching 문제로 인해, mixture model의 파라미터가 unidentifiable 해짐
- 예시
 - 실제 데이터는 2개의 GMM (Gaussian Mixture Model) 클러스터로 구성
 - 2개의 GMM 클러스터를 갖는 모델 학습
 - MLE는 KL-divergence를 최소화하는 $\hat{\theta}$ 를 찾음

$$D_{\text{KL}} \left(p(\mathbf{x} | \boldsymbol{\theta}^*) \parallel p(\mathbf{x} | \hat{\boldsymbol{\theta}}) \right)$$

- GMM은 각 클러스터에 label이 없으니, [1]과 [2]는 동일한 결과

$$[1] \quad \hat{\mu}_1 = \mu_1^*, \hat{\mu}_2 = \mu_2^*$$

$$[2] \quad \hat{\mu}_2 = \mu_1^*, \hat{\mu}_1 = \mu_2^*$$

- 그러나 베이지안 추론에서는 이를 다르게 인식하고, posterior mean of μ_k 계산
→ 존재하지 않는 잘못된 클러스터 결과
- proposes a decision theoretic approach → label alignment

28.3 Factor analysis

28.3.1 Factor analysis: the basics

- linear-Gaussian latent variable generative model
- 잠재 변수 z 의 prior

$$p(z) = \mathcal{N}(z \mid \mu_0, \Sigma_0)$$

- 잠재 변수 z 로부터 실제 데이터 x 가 어떻게 생성되는지에 대한 likelihood

$$p(x \mid z, \theta) = N(x \mid Wz + \mu, \Psi)$$

- W : factor loading matrix. $D \times L$ matrix, **저차원의 잠재 공간**에서 나온 z 를 고차원 공간

x로 mapping

- $Wz + \mu$: 예측 평균. 잠재 변수 z 를 선형변환한 뒤 평균 μ 를 더한 값
- Ψ : $D \times D$ covariance matrix. 각 feature에 대한 독립적인 노이즈

| FA as a Gaussian with low-rank plus diagonal covariance

- marginal likelihood

$$\begin{aligned} p(x | \theta) &= \int N(x | Wz + \mu, \Psi) N(z | \mu_0, \Sigma_0) dz \\ &= \mathcal{N}(x | W\mu_0 + \mu, \Psi + W\Sigma_0W^\top) \end{aligned}$$

- 모델 더 간단하게 표현

- we can always absorb $W\mu_0$ into $\mu \rightarrow \mu_0 = 0$
- we can always absorb a correlated prior by using a new weight matrix,

$$\tilde{W} = W \Sigma_0^{-\frac{1}{2}}, \text{Cov}[x] = W\Sigma_0W^\top + \Psi = \tilde{W}\tilde{W}^\top + \Psi$$

- final model

$$\begin{aligned} p(z) &= \mathcal{N}(z | \mu_0, \Sigma_0) \\ p(x | z, \theta) &= N(x | Wz + \mu, \Psi) \\ p(x) &= \mathcal{N}(x | \mu, WW^\top + \Psi) \end{aligned}$$

- 예시

- suppose $L = 1, D = 2$ and $\Psi = \sigma^2 I$




Figure 28.6: Illustration of the FA generative process, where we have $L = 1$ latent dimension generating $D = 2$ observed dimensions; we assume $\Psi = \sigma^2 I$. The latent factor has value $z \in \mathbb{R}$, sampled from $p(z)$; this gets mapped to a 2d offset $\delta = zw$, where $w \in \mathbb{R}^2$, which gets added to μ to define a Gaussian $p(x|z) = \mathcal{N}(x | \mu + \delta, \sigma^2 I)$. By integrating over z , we “slide” this circular Gaussian “spray can” along the principal component axis w , which induces elliptical Gaussian contours in x space centered on μ . Adapted from Figure 12.9 of [Bis06].

- (원) 1차원 정규분포에서 잠재변수 sampling : $z \sim \mathcal{N}(0, 1)$
- (중) 잠재공간 $\rightarrow$ 관측공간 : $\mu + zw = \mu + \delta, p(x | z) = N(wz + \mu, \sigma^2 I)$
- (오) 관측값 x sampling : 노이즈 더해주고 marginal distribution을 구하면, $p(x) = N(x | \mu, ww^\top + \sigma^2 I)$.
- FA는 low-rank decomposition을 이용해서 공분산 행렬을 근사한 것이다

$$C = \text{Cov}[x] = WW^\top + \Psi$$

- only uses $O(LD)$ parameters

- flexible compromise between a full covariance Gaussian($O(D^2)$) and a diagonal covariance($O(D)$)

Model fitting using EM

- In the E step
 - 관측값 x_n 이 주어졌을 때 어떤 z_n 에서 왔는지 추론
 - 충분 통계량 $E_{X,Z}, E_{Z,Z}, E_{X,X}$ 계산

$$\mathbf{E}_{x,z} = \sum_{n=1}^N \mathbf{x}_n \mathbb{E}[z|\mathbf{x}_n]^T \quad (28.51)$$

$$\mathbf{E}_{z,z} = \sum_{n=1}^N \mathbb{E}[zz^T|\mathbf{x}_n] \quad (28.52)$$

$$\mathbf{E}_{x,x} = \sum_{n=1}^N \mathbf{x}_n \mathbf{x}_n^T \quad (28.53)$$

where

$$\mathbb{E}[z|\mathbf{x}] = \mathbf{B}\mathbf{x} \quad (28.54)$$

$$\mathbb{E}[zz^T|\mathbf{x}] = \text{Cov}[z|\mathbf{x}] + \mathbb{E}[z|\mathbf{x}]\mathbb{E}[z|\mathbf{x}]^T = \mathbf{I} - \mathbf{B}\mathbf{W} + \mathbf{B}\mathbf{x}\mathbf{x}^T\mathbf{B}^T \quad (28.55)$$

$$\mathbf{B} \triangleq \mathbf{W}^T(\Psi + \mathbf{W}\mathbf{W}^T)^{-1} = \mathbf{W}^T\mathbf{C}^{-1} \quad (28.56)$$

- In the M step
 - E step에서 계산한 통계량으로 $\mathbf{W}, \Psi$ 업데이트

$$\begin{aligned} \mathbf{W}^{\text{new}} &= \mathbf{E}_{x,z} \mathbf{E}_{z,z}^{-1} \\ \Psi^{\text{new}} &= \frac{1}{N} \text{diag}(\mathbf{E}_{x,x} - \mathbf{W}^{\text{new}} \mathbf{E}_{x,z}^T) \end{aligned}$$

Ψ = 전체 x 공분산 - (잠재변수로 설명가능한 부분) $\rightarrow$ 대각성분만 추출
 Ψ 가 비대각행렬이면, 노이즈 자체가 상관관계를 생성할 수 있어 잠재변수의 의미 사라짐

Handling missing data

- 관측치가 일부만 있을 때도 FA 모델에서 잠재변수 z 의 분포를 구하는 posterior inference를 할 수 있다
- partition
 - $x = (x_1, x_2), \mathbf{W} = [\mathbf{W}_1, \mathbf{W}_2], \mu = [\mu_1, \mu_2]$
 - x_2 : missing(unknown)

$$\begin{aligned} p(z|\mathbf{x}_1) &= \mathcal{N}(z|\mu_{z|1}, \Sigma_{z|1}) \\ \Sigma_{z|1}^{-1} &= \mathbf{I} + \mathbf{W}_1^T \Sigma_{11}^{-1} \mathbf{W}_1 \\ \mu_{z|1} &= \Sigma_{z|1} [\mathbf{W}_1^T \Sigma_{11}^{-1} (\mathbf{x}_1 - \mu_1)] \end{aligned}$$

where Σ_{11} is the top left block of Ψ .

Unidentifiability of the parameters

- FA 모델에서의 Covariance

$$\text{Cov}[\mathbf{x}] = \mathbf{W} \mathbb{E}[\mathbf{z}\mathbf{z}^T] \mathbf{W}^T + \mathbb{E}[\boldsymbol{\epsilon}\boldsymbol{\epsilon}^T] = \mathbf{W}\mathbf{W}^T + \boldsymbol{\Psi}$$

- consider a different model with weights $\tilde{\mathbf{W}} = \mathbf{W}\mathbf{R}$, satisfying $\mathbf{R}\mathbf{R}^T = \mathbf{I}$

$$\text{Cov}[\mathbf{x}] = \tilde{\mathbf{W}} \mathbb{E}[\mathbf{z}\mathbf{z}^T] \tilde{\mathbf{W}}^T + \mathbb{E}[\boldsymbol{\epsilon}\boldsymbol{\epsilon}^T] = \mathbf{W}\mathbf{R}\mathbf{R}^T\mathbf{W}^T + \boldsymbol{\Psi} = \mathbf{W}\mathbf{W}^T + \boldsymbol{\Psi}$$

- 다른 모델인데, 같은 likelihood를 갖게됨
 - cannot uniquely identify $\mathbf{W}$
 - cannot uniquely identify the latent factors
- “factor rotations problem”이라 불린다
 - $\mathbf{z} \sim N(0, \mathbf{I})$ 는 모든 방향에서 분산이 같은 isotropic gaussian
 - $\mathbf{z}$ 를 어떤 직교 행렬 $\mathbf{R}$ 로 회전시켜도 그 분포는 동일
- 이 문제를 해결하기 위한 시도들
 - Forcing $\mathbf{W}$ to be lower triangular

$$\mathbf{W} = \begin{pmatrix} w_{11} & 0 & 0 \\ w_{21} & w_{22} & 0 \\ w_{31} & w_{32} & w_{33} \\ w_{41} & w_{42} & w_{43} \end{pmatrix}$$

- $\mathbf{W}$ 의 구조에 제약을 걸어 회전 가능성 제거
- $\mathbf{R}$ 과 곱했을 때 다시 lower triangular이 되지 않음
- 단점: 첫 번째 관측 변수들(“founder variables”)이 가장 먼저 latent factor에 반응하도록 설계되므로, bias가 생길 수 있어 founder variables를 신중하게 선택해야함
- Sparsity promoting priors on the weights
 - 미리 지정하지 말고, $\mathbf{W}$ 의 값이 자연스럽게 0이 되도록 유도
 - l_1 정규화, ARD 등 이용
 - “sparse factor analysis”라 부른다($\mathbf{W}$ 의 많은 항목들이 0이 되도록 유도하여, 소수의 잠재 요인에만 영향을 받는다는 관점)
- Choosing an informative rotation matrix
 - 희소성을 유도하는 방향으로 $\mathbf{R}$ 찾는 heuristic한 방법 적용
 - 널리 사용하는 방법 중 하나 varimax
 - 요소들이 각 관측 변수에 고르게 퍼지지 않고, 소수의 요소에만 집중되도록(희소하게) 회전시키는 방식
- Use of non-Gaussian priors for the latent factors
 - 잠재변수 $\mathbf{z}$ 에 정규분포가 아닌 분포로 바꾸면, $\mathbf{W}$ 와 잠재 변수 모두 uniquely identify할 수 있다

28.6 Independent components analysis (ICA)

- cocktail party problem 🍷

- 많은 사람들이 이야기하고 있는 공간에 있을 때,
- 당신의 두 귀는 두개의 마이크처럼 작동해서 그 방 안의 서로 다른 음성 신호의 선형 결합을 듣고 있다
- 여기서 목표는 mixed signal을 원래 신호로 분리해내는 것
- 이 문제는 EEG(뇌파), MEG(자기 뇌파) 분석, 금융 데이터의 상황에서도 발생한다

28.6.1 Noiseless ICA model

- formalizing the problem
 - $x_n \in R_D$: 관측된 신호 벡터
 - $z_n \in R_D$: 숨겨진 소스 신호
 - D : 마이크의 개수 = 신호 차원
 - n : time
 - prior

$$p(x_n) = \prod_{j=1}^D p_j(z_j)$$

- 주로 sparse prior 가정, 동시에 활성화된 signal이 소수라고 생각

- Independent Components Analysis
 - assume that each observation x_n is a linear combination of independent components represented by sources z_n

$$x_{nj} = \sum_i A_{ij} z_{nj}$$

- $\mathbf{A} \in \mathbb{R}^{D \times D}$: **generative weights**(즉, 어떻게 x로부터 관측값이 생성되었는가를 나타내는 생성 가중치)

- goal : infer $p(z_n | x_n, A)$

- model이 noiseless라면,

$$p(z_n | x_n, A) = \delta(z_n \leftrightarrow Bx_n)$$

- $B = A^{-1}$ (recognition weight)
- 어떤 분포 함수 δ

28.6.2 The need for non-Gaussian priors

- ICA의 기본 모델

$$x = Az$$

- to uniquely identify A,
 - independent한 non-gaussian prior 적용




Figure 28.33: Illustration of ICA and PCA applied to 100 iid samples of a 2d source signal with a uniform distribution. Generated by [ica_demo_uniform.ipynb](#).

- source signal이 잠재 변수
- (a) : 원본 데이터, (b) : 관측 데이터
- (c) : PCA를 적용한 결과, 데이터의 공분산을 단위 행렬로 만들어줌. (a)랑 비슷하기는한데, 회전이 가능한 상태여서 Unique하게 original source signal을 확인할 수 없다
- (d) : PCA 한계 보완하기 위해 additional rotation 수행. 적절한 appropriate rotation을 찾기 위해, independent non-gaussian prior 사용 ⇒ ICA !
- (a)랑 (d)가 제일 비슷함

- 보통 prior로 super-Gaussian distribution 많이 쓴다
 - heavy tail을 갖고 있어 identifiability를 높이는데 도움이 많이됨.
 - 예1) Laplace prior(mean 0, variance 1)
 - log pdf

$$\log p(z) = -\sqrt{2}|z| - \log(\sqrt{2})$$

- 예2) logistic distribution
 - Laplace prior의 미분불가능 문제 해결
 - log pdf(mean 0, variance 1)

$$\log p(z) = \log \text{sech}^2(z/2s) - \log(4s) = -2 \log \cosh\left(\frac{\pi}{2\sqrt{3}}z\right) - \log \frac{4\sqrt{3}}{\pi}$$

Conclusion

- Latent variable models
 - 관측 데이터를 생성하는 메커니즘에 대해 확률적 모델
 - 잠재변수 z 도입

- 그 중 하나가 Latent factor models
 - Mixture Model, PCA, ICA, ...