

12.1 Introduction

- MCMC (Markov Chain Monte Carlo)

- 고차원 분포로부터의 샘플링에 널리 사용되는 방법

- Markov Chain

- 어떤 상태에서 다른 상태로 넘어갈 때, 바로 전 단계의 상태에만 영향을 받는 확률 과정

ex. 보통 사람들은 전날 먹은 식사와 유사한 식사를 하지 않으려는 경향이 있다.

가령, 어제 짜장면을 먹었다면 오늘은 면종류의 음식을 먹으려고 하지 않는다.


→ 어제 먹은 음식에만 영향 받고, 그저께 먹은 음식에는 영향 x. 이 과정은 '마르코프 성질'을 가진다고 할 수 있고, 이 확률 과정이 Markov chain

- Monteo Carlo

- 통계적인 수치를 얻기 위해 수행하는 '시뮬레이션'
- 해석적으로 구하기 어려운 함수 값을 샘플링을 통해서 '근사적'으로 구하고자 하는 방법론

- MCMC (Markov Chain Monte Carlo)

- 첫 샘플을 랜덤하게 선택한 뒤, 첫 샘플에 의해 그 다음번 샘플이 추천되는 방식을 무수하게 시도하면서 샘플을 추출하는 알고리즘
- basic idea
 - state space $\mathcal{X}$ 상에서 Markov Chain을 구성하는 것
 - └ 어떤 Markov chain?
 - : Markov chain의 stationary distribution이 target 확률 밀도 함수 $p^*(x)$
 - *state space : 샘플을 뽑고 싶은 공간
 - *stationary distribution : 마르코프 체인이 충분히 오랜 시간 동안 상태를 이동한 후에 수렴하게 되는 확률 분포
 - state space에서 random walk 수행
 - each state $\mathbf{x}$ 에 머무는 시간의 비율은 $p^*(x)$ 에 비례
 - Markov chain으로부터 samples를 이끌어낼 수 있다
 - 전반적인 과정
 0. 목표 : 타겟 분포 $p(x)$ 를 따르는 샘플 추출하고 싶다
 1. random initialization x^s
 2. 제안 분포 $q(x)$ 를 이용해서 샘플 x^{s+1} 제안
 - acceptance probability 이용해 accept or reject 과정 무수히 반복



12.2 MH algorithm

- Metropoli-Hastings(MH) algorithm
 - simplest kinds of MCMC algorithm

12.2.1 Basic Idea

Algorithm 12.1: Metropolis-Hastings algorithm

```

1 Initialize  $x^0$ 
2 for  $s = 0, 1, 2, \dots$  do
3   Define  $x = x^s$ 
4   Sample  $x' \sim q(x'|x)$ 
5   Compute acceptance probability
      
$$\alpha = \frac{\tilde{p}(x')q(x|x')}{\tilde{p}(x)q(x'|x)}$$

6   Compute  $A = \min(1, \alpha)$ 
7   Sample  $u \sim U(0, 1)$ 
8   Set new sample to
      
$$x^{s+1} = \begin{cases} x' & \text{if } u \leq A \text{ (accept)} \\ x^s & \text{if } u > A \text{ (reject)} \end{cases}$$


```

- [2] 각 단계에서
 - [3-4] current state x to a new state x' 로의 이동을 $q(x'|x)$ 확률로 제안
 - q : proposal distribution
 - 어떤 종류의 제안 분포든 사용할 수 있어 MH algorithm은 매우 유연
 - [5-8] x' 로의 이동을 accept or reject 결정
 - 수락 기준 : 각 상태에 머무는 시간 비율이 우리가 원하는 분포 $p^*(x)$ 에 비례하도록 보장
 - (1) proposal distribution is symmetric, $q(x'|x) = q(x|x')$

$$\text{acceptance probability } A = \min \left(1, \frac{p^*(x')}{p^*(x)} \right) \quad (12.1)$$

- $p^*(x') > p^*(x)$ 이면, 무조건 이동
- (만약 $p^*(x') < p^*(x)$ 여도, 확률 비율에 따라 이동할 수도 있음)
- (2) proposal distribution is assymmetric, $q(x'|x) \neq q(x|x')$

acceptance probability $A = \min(1, \alpha)$

$$\alpha = \frac{p^*(x')q(x|x')}{p^*(x)q(x'|x)}$$

- Hastings 보정 필요(어떠한 상태로 치우치지 않도록)
- ▼ acceptance probability를 계산할 때, 정규화되지 않은 확률 밀도만 알면 되므로 유용

$$p^*(x) = \frac{1}{Z} \tilde{p}(x),$$

$\tilde{p}(x)$: unnormalized distribution, Z : normalization constant

$$\alpha = \frac{(\tilde{p}(x')/Z) \cdot q(x|x')}{(\tilde{p}(x)/Z) \cdot q(x'|x)}$$

- Z 몰라도 A 계산 가능

12.2.2 Why MH works

- 원하는 분포 $p^*(x)$ 를 **stationary distribution**으로 갖는 **마르코프 체인**을 정의하기 때문
- MH 알고리즘은 전이 행렬 $p(x'|x)$ 를 갖는 마르코프 체인 정의

$$p(x'|x) = \begin{cases} q(x'|x) \cdot A(x'|x), & \text{if } x' \neq x \\ q(x|x) + \sum_{x' \neq x} q(x'|x)(1 - A(x'|x)), & \text{if } x' = x \end{cases} \quad (1)$$

- $x \rightarrow x'$ 로 움직이는 경우 : $q(x'|x) \cdot A(x'|x)$
- x 에서 움직이지 않는 경우 : 자기자신 제안했을 확률 + 다른 상태 제안했지만 거절될 확률
- $p(x'|x)p^*(x) = p(x|x')p^*(x')$ 일 때, chain은 detailed balance 만족
 - x 에서 x' 으로 들어가는 in-flow = x' 에서 x 로 나오는 out-flow
 - detailed balance 만족하면, 그 체인의 **stationary distribution**은 p^*
- 우리의 목표는 **Metropolis-Hastings(MH) 알고리즘이 detailed balance 조건을 만족하는 전이 함수**를 정의한다는 것을 보여주는 것 논리적 공백이 없는지... 이대로 스킵해도 ㅏㅏ은 것인지.. 확인

12.2.3 Proposal distributions

- 12.2.3.1 Independence sampler

$$q(x'|x) = q(x')$$

- 새로운 상태 x' 이 x 랑 독립이라면, $q(x')$ 은 적절한 분포라면 뭐든 될 수 있음(ex. Gaussian)

- 12.2.3.2 Random walk Metropolis (RWM) algorithm

$$q(x'|x) = N(x'|x, \tau^2 I)$$

- 현재 상태 x 를 기준으로 조금씩 움직이기
- 방향 & 크기는 정규분포에서 샘플링

- 분산 τ^2 를 잘 조절하는게 핵심

- 12.2.3.3 Composing proposals

$$q(x' | x) = \sum_{k=1}^K w_k q_k(x' | x)$$

- notation
 - $q_k(x' | x)$: 유효한 제안 분포
 - w_k : 가중치 (전부 합치면 1)
- 각 제안 분포가 detailed balance 만족하면, mixture $q(x'|x)$ 도 만족
- chain도 가능

$$q(x' | x) = \sum_{x_1} \cdots \sum_{x_{K-1}} q_1(x_1 | x) q_2(x_2 | x_1) \cdots q_K(x' | x_{K-1})$$

- 12.2.3.4 Data-driven MCMC

- target distribution $p^*(x) = p(x|D)$ 일 때 유용
- train a recognition network f

$$q(x'|x, D) = f(x)$$

- if the state space is high-dimensional
 - alternatively train individual "experts" to predict specific pieces of the hidden state

$$q(x'|x, D) = \pi_0 q_0(x'|x) + \sum_k \pi_k q_k(x'_k | f_k(D))$$

- notation
 - q_0 : standard data-independent proposal (e.g., random walk)
 - q_k : updates the k'th component of the state space
 - π : weight
- 전체적인 과정
 - (1) $q(x'|x, D)$ 생성
 - (2) posterior ratio $\frac{p(x'|D)}{p(x|D)}$ 계산해서 평가

- 12.2.3.5 Adaptive MCMC

- 알고리즘이 실행되는 도중에 **proposal의 파라미터를 조정**해서 효율 높이는 방식
- 처음 : broad covariance → 공간 전체 탐색
- 점차 : narrowing covariance로 mode 근처 탐색

12.4 Auxiliary variable MCMC

- 변수들 간의 상관 관계 줄이기 위해 보조 변수 도입

- joint sample $(x^s, v^s) \sim p(x, v)$ 를 샘플링한 후, v^s 는 버리고 x 만 남김

$$x_s \sim \sum_v p(x, v)$$

12.4.1 Slice sampling

- 샘플링하고 싶은 분포 : univariate but multimodal distribution $p(x) = \frac{\tilde{p}(x)}{Z_p}$, $Z_p = \int \tilde{p}(x) dx$
- Z_p 를 몰라서 샘플링 어려움

→ adding a uniform auxiliary variable v !

- joint distribution

$$\hat{p}(x, v) = \begin{cases} \frac{1}{Z_p} & \text{if } 0 \leq v \leq \tilde{p}(x) \\ 0 & \text{otherwise} \end{cases}$$

- marginal distribution over x

$$\int \hat{p}(x, v) dv = \int_0^{\tilde{p}(x)} \frac{1}{Z_p} dv = \frac{\tilde{p}(x)}{Z_p} = p(x)$$

- v 를 버리면 $x \sim p(x)$ 샘플 보장

- (step 1) Given previous sample x^i , we sample v^{i+1} from 근데 왜 자꾸 i+1이지

$$p(v|x^i) = U_{[0, \tilde{p}(x^i)]}(v)$$

- $0 \sim \tilde{p}(x^i)$ 까지 수직선 하나 세우고, 무작위로 하나 고르는 것과 같음

- (step 2) construct a slice A^{i+1}

$$A^{i+1} = x : \tilde{p}(x) \geq v^{i+1}$$

- 밀도 $\tilde{p}(x)$ 가 v^{i+1} 보다 큰 영역이 나오지 않을 때까지 **양쪽으로 확장**해가면서 슬라이스 영역을 찾는 stepping out 반복

- (step 3) sample x^{i+1} uniformly from this set **영역 맞는지 체크**




Figure 12.7: Slice sampling. (a) Illustration of one step of the algorithm in 1d. Given a previous sample x^i , we sample u^{i+1} uniformly on $[0, f(x^i)]$, where $f = \tilde{p}$ is the (unnormalized) target density. We then sample x^{i+1} along the slice where $f(x) \geq u^{i+1}$. From Figure 15 of [And+03]. Used with kind permission of Nando de Freitas. (b) Output of slice sampling applied to a 1d distribution. Generated by [slice_sampling_demo_1d.ipynb](#).

12.6 MCMC convergence

- MCMC 샘플링은 어떤 초기 상태에서 시작 → 시간이 지나면서 우리가 원하는 stationary distribution에 수렴
 - burn-in phase : 초기 상태의 영향을 강하게 받아 버려야 하는 initial period
 - mixing time : stationary distribution으로 수렴하는데까지 걸리는 시간
- 예시
 - sampling using a symmetric random walk
 - 200번 이상 반복해야 체인이 어디서 시작되었는지 잊게됨




Figure 12.11: Illustration of convergence to the uniform distribution over $\{0, 1, \dots, 20\}$ using a symmetric random walk starting from (left) state 10, and (right) state 17. Adapted from Figures 29.14 and 29.15 of [Mac03]. Generated by `random_walk_integers.ipynb`.

12.6.1 Mixing rates of Markov chains

- Mixing Time τ_ϵ
 - mixing time from the state x_0
- $$\tau_\epsilon(x_0) = \min \{t : \|\delta_{x_0} T^t - p^*\|_1 \leq \epsilon\}$$
- notation
 - $\delta_{x_0}(x)$: distribution with all its mass in state x_0
 - T : the transition matrix of the chain which depends on the target p^* and the proposal q
 - $\delta_{x_0}(x) T^t$: distribution after t steps
 - mixing time of the chain (= worst case)

$$\tau_\epsilon(x_0) = \max_{x_0} \tau_\epsilon(x_0)$$

- mixing time is determined by the eigen gap $\gamma = \lambda_1 - \lambda_2$
 - difference between the first and second eigenvalues of the transition matrix
 - geometry of the state space
 - 체인이 x^1, x^2, x^3 중 한 곳에서 시작하면 그 내부를 빠르게 탐색
 - $x^4 \sim x^7$ 로 넘어가는데는 매우 오래 걸림
- 병목 현상




Figure 12.12: A Markov chain with low conductance. The dotted arcs represent transitions with very low probability. From Figure 12.6 of [KF09a]. Used with kind permission of Daphne Koller.

low conductance = mixing time 길어짐

12.6.2 Practical convergence diagnostics

- transition matrix를 계산하기 힘들기 때문에, chain의 mixing time을 계산하는 것은 일반적으로 어려움
- 수렴을 계산적으로 판단하는 것은 어려워, heuristic한 방법으로 확인
- 12.6.2.1 Trace plots
 - 여러 개의 체인(보통 3-4개)을 서로 다른 시작점에서 시작해서 돌려보고,
 - 관심 있는 값(ex. value of a certain component of the state vector)을 각 체인에서 시간에 따라 그려봄 → 체인의 궤적 시각화
 - MCMC가 잘 수렴했다면,
 - 초기 상태의 영향은 "잊고", 서로 다른 체인들이 같은 분포에 수렴해서 비슷한 구간을 움직이며 overlap하는 형태여야 함
 - 예시
 - model : a univariate Gaussian, $y_i \sim N(\alpha, \sigma)$, with just 2 observations, $y_1 = -1$ and $y_2 = +1$
 - using HMC using 3 chains and 500 samples
 - diffuse prior : $\alpha \sim N(0, 1000)$ and $\sigma \sim Expon(0.0001)$
 - prior가 매우 넓고 & 데이터 포인트 2개 = likelihood의 영향력 약함
 - prior가 거의 그대로 posterior로 이어짐
 - sensible prior : $\alpha \sim N(1, 10)$ and $\sigma \sim Expon(1)$
 - Trace plot
 - diffuse prior




Figure 12.13: Marginals (left) and trace plot (right) for the univariate Gaussian using the diffuse prior. Black vertical lines indicate HMC divergences. Adapted from Figures 9.9–9.10 of [McE20]. Generated by [mcmc_traceplots_unigauss.ipynb](#).

- marginal plot(왼쪽) : 세 chain의 분포가 전혀 겹치지 않음 → 수렴 x
- trace plot(오른쪽) : 세 chain이 서로 다른 구간을 왔다 갔다함 → 수렴 x
- sensible prior




Figure 12.14: Marginals (left) and trace plot (right) for the univariate Gaussian using the sensible prior. Adapted from Figures 9.9–9.10 of [McE20]. Generated by `mcmc_traceplots_unigauss.ipynb`.

- marginal plot(왼쪽) : 세 chain의 분포가 거의 겹침 & MLE 근처($\alpha=0, \sigma=1$)에서 peak 형성
- trace plot(오른쪽) : 세 chain이 비슷한 구간에서 진동 & 서로 overlap하며 수렴된 상태
- Trace rank plot
 - 각 체인의 샘플이 전체 샘플들 중에서 어느 순위(rank)에 있는지 표현
 - MCMC가 잘 수렴했다면,
 - distribution over ranks should be uniform




Figure 12.15: Trace rank plot for the univariate Gaussian using the diffuse prior. Adapted from Figures 9.9–9.10 of [McE20]. Generated by `mcmc_traceplots_unigauss.ipynb`.




Figure 12.16: Trace rank plot for the univariate Gaussian using the sensible prior. Adapted from Figures 9.9–9.10 of [McE20]. Generated by `mcmc_traceplots_unigauss.ipynb`.

- diffuse prior(Figure 12.15, 상단)보다 sensible prior(Figure 12.16, 하단)이 더 고른 분포를 보이고 있음
- 12.6.2.2 Estimated potential scale reduction (EPSR)
 - basic idea
 - MCMC가 잘 수렴했다면, chain 간 variance와 chain 내 variance이 비슷할 것이다
 - notation

- M : 체인의 수, N : 각 체인의 샘플 수
- x_{nm} : m번째 체인의 n번째 샘플
- $\bar{x}_m$: m번째 체인의 평균
- $\bar{x}.$: 모든 체인의 전체 평균
- Within-chain variance W
 - s_m^2 : m번째 체인의 샘플 분산

$$W = \frac{1}{M} \sum_{m=1}^M s_m^2$$

- Between-chain variance B

$$B = \frac{N}{M-1} \sum_{m=1}^M (\bar{x}_m - \bar{x}.)^2$$

▼ N을 곱하는 이유

$$\begin{aligned} \text{Var}(\bar{x}) &= \frac{\sigma^2}{N} \\ \sigma^2 &\approx N \cdot \text{Var}(\bar{x}_m) \end{aligned}$$

- ESPR $\hat{R}$
 - V : Posterior variance 추정치

$$V = (1 - \frac{1}{N})W + \frac{1}{N}B$$

$$\hat{R} = \sqrt{\frac{V}{W}}$$

- 이 값이 1에 가까우면 수렴한다고 판단

12.6.3 Effective Sample Size

- 실제 독립적인 샘플로는 몇개와 같은지를 확인한다는 개념
- MCMC 샘플은 일반적으로 서로 독립하지 않고, correlated
 - 샘플 간 상관계수가 많을수록 평균의 분산이 커지고, 정확도 많아진다

▼ Cov를 corr로 표현

$$\text{corr}[x_i, x_j] = \frac{\text{Cov}[x_i, x_j]}{\sqrt{\mathbb{V}[x_i] \mathbb{V}[x_j]}}$$

$$\begin{aligned} \text{Var}[\bar{x}] &= \text{Var}\left[\frac{1}{N} \sum_{n=1}^N x_n\right] = \frac{1}{N^2} \sum_{i=1}^N \sum_{j=1}^N \text{Cov}[x_i, x_j] \\ &= \frac{\sigma^2}{N^2} \sum_{i=1}^N \sum_{j=1}^N \text{corr}[x_i, x_j] \end{aligned}$$

- autocorrelation time 이용해서 정리

$$\rho = 1 + 2 \sum_{\ell=1}^{\infty} \rho(\ell),$$

where $\rho(\ell) \triangleq \text{corr}[x_0, x_\ell]$

▼ ρ 형태 정리

from i . As $N \rightarrow \infty$ we can approximate the sum of correlations by

$$\sum_{j=1}^N \text{corr}[x_i, x_j] \rightarrow \sum_{\ell=-\infty}^{\infty} \text{corr}[x_i, x_{i+\ell}] = 1 + 2 \sum_{\ell=1}^{\infty} \text{corr}[x_i, x_{i+\ell}]$$

- For a fixed i , $\text{corr}[x_i, x_i] = 1$ and $\text{corr}[x_i, x_{i-\ell}] = \text{corr}[x_i, x_{i+\ell}]$ for lag $\ell > 0$
- we assume the samples are coming from a "stationary distribution", the index i does not matter
- Effective Sample Size
 - correlation이 클수록, 효과적인 샘플 수 줄어든다

$$\begin{aligned} \text{Var}[\bar{x}] &= \frac{\sigma^2}{N^2} \sum_{i=1}^N \sum_{j=1}^N \text{corr}[x_i, x_j] \\ &= \frac{\sigma^2}{N^2} \sum_{i=1}^N \rho = \frac{\sigma^2}{N} \rho, \text{ where } \rho = 1 + 2 \sum_{\ell=1}^{\infty} \rho(\ell) \end{aligned}$$

$$N_{\text{eff}} \triangleq \frac{\rho}{N} = \frac{N}{1 + 2 \sum_{\ell=1}^{\infty} \rho(\ell)}$$

▼ In practice

- 이론적으로는 무한히 더해야하지만, 현실적으로 다음과 같이 계산

$$\hat{N}_{\text{eff}} = \frac{NM}{1 + 2 \sum_{\ell=1}^L \hat{\rho}(\ell)}$$

- notation
 - M : 체인의 수, N : 각 체인의 샘플 수
 - L : ACF가 0이 되기 전까지의 lag
 - $\hat{\rho}(\ell)$: 샘플로 추정된 lag- ℓ 의 auto correlation




Figure 12.17: Autocorrelation functions for various MCMC samplers for the mixture of two 1d Gaussians. (a-c) These are the MH samplers in Figure 12.1. (d) This is the Gibbs sampler in Figure 12.4. Generated by [mcmc_gmm_demo.ipynb](#).

- worse case
 - (a) : 제안 분포의 분산이 작아서 → 샘플이 조금씩 움직임 → 자기상관 큼
 - (b) : 제안 분포의 분산이 커서, 샘플 크게 움직임 → 대부분 제안 거절 → 자기상관 큼
- good case
 - (c) : 적당한 제안 분포의 분산 → 빠르게 자기상관 줄어듦
 - (d) : 각 변수의 조건부 분포로 직접 샘플링 → 빠르게 자기상관 줄어듦

12.6.4 Improving speed of convergence

- Try using a non-centered parameterization / sampling variables in groups or blocks / Rao-Blackwellization / adding auxiliary variable / adaptive proposal distributions

12.9 Annealing methods

- 실제 다루는 많은 분포들은 multimodal → local mode에 갇혀버릴 수 있음
- molecules align을 위한 금속 열처리 방법에서 아이디어
 - 분포를 부드럽게 만들고, 점점 기존의 울퉁불퉁한 분포로 돌아오는 방식
- 여기서는 **MAP (Maximum a Posteriori) 추정** 문제에 먼저 적용한 뒤,
- 나중에는 **샘플링(sampling)** 문제로 확장

12.9.1. Simulated annealing algorithm

- MH 알고리즘의 변형
- blackbox 함수의 global optimum을 찾는 것이 목표

- 적용할 아이디어: Annealing
 - a physical process of heating a solid until thermal stresses are released
 - 서서히 냉각시키면 안정적인 구조로 정렬됨
 - 에너지가 최소화된 상태에 도달
- 이걸 확률분포에 적용하여 number of modes(low energy states) control

$$p_T(x) = \exp(-E(x)/T),$$

$T : \text{temperature}$

- ex: Peaks Function

$$p(x, y) \propto 3(1-x)^2 e^{-x^2-(y+1)^2} - 10\left(\frac{x}{5} - x^3 - y^5\right) e^{-x^2-y^2} - \frac{1}{3} e^{-(x+1)^2-y^2}$$

- Temperature

- high temperature $T \gg 1$

: 전체가 평평해짐 → 모든 위치에서 자유롭게 이동 가능 (local minima 탈출 쉬움)

- low temperature $T \ll 1$

: 큰 피크는 더 커지고, 작은 피크는 사라짐 → global optimum으로 수렴




Figure 12.22: Annealed version of the distribution in Figure 12.21a at different temperatures. Generated by [simulated_annealing_2d_demo.ipynb](#).

- 구체적인 작동 방식

- at each step, sample a new state according to some proposal distribution

$$x' \sim q(\cdot | x_t)$$

- (real-valued parameter는 보통 random walk proposal 방식 이용, $x' = x_t + \epsilon_{t+1}, \epsilon_{t+1} \sim N(0, \Sigma)$)

- acceptance probability

$$\alpha_{t+1} = \exp(-(E(x') - E(x_t))/T_t)$$

- (accept) $\min(1, \alpha_{t+1}), x_{t+1} = x' \Rightarrow$ 'lower energy'
- (reject) $\min(1, \alpha_{t+1}), x = x' \Rightarrow$ 'higher energy'
- exponential cooling schedule

$$T_{t+1} = \gamma T_t, \text{ where } \gamma \in (0, 1]$$

- 너무 빠르면 local optimum에 갇힐 수 있고, 너무 느리면 시간이 많이 소요됨
- cooling schedule을 잘 결정하는 것이 중요한데 어려워 단점으로 꼽힘

- cooling schedule $\gamma = 0.9$, Gaussian random walk($\sigma=10$)

- (b) : 샘플들이 global optimum(오른쪽 중앙 피크)에 점점 집중됨 (a) figure 탐구




Figure 12.23: Simulated annealing applied to the distribution in Figure 12.21a. (a) Temperature vs iteration and probability of each visited point vs iteration. (b) Visited samples, superimposed on the target distribution. The big red dot is the highest probability point found. Generated by [simulated_annealing_2d_demo.ipynb](#).

12.9.2 Parallel tempering

- MCMC와 annealing을 결합하는 또 다른 방법
- 서로 다른 온도를 갖는 여러 개의 체인을 병렬로 돌리는 것
- 온도가 비슷한 체인끼리 샘플을 교환
 - state space를 멀리까지 탐색하는 높은 온도의 체인이 낮은 온도의 체인에게도 영향