



[중요] 수리통계학 I & II 및 연습

▼ Chap 1. 확률과 확률분포

- 통계에서 수학적 이론을 도입하는 근본 목적 : 확률실험에 대한 수학적 모형 제시
 ■ 실험에 대한 모형이 채택되어 이론적으로 전개되면 이 테두리 안에서 확률실험에 관한 추론(=결론) 내린다

1.2 Sets

- 드모르간의 법칙

$$(A \cap B)^c = A^c \cup B^c$$

- 정의역 : X, 공역 : Y

1.3 The Probability Set Function

- 3가지 조건을 만족하면, 실험수 P를 확률집합함수라고 표현할 수 있는데 확률의 3가지 조건과 동일
- 확률의 연속 정리

$\{C_n\}$ 을 사건의 증가열이라고 하면

$$\lim_{n \rightarrow \infty} P(C_n) = P(\lim_{n \rightarrow \infty} C_n) = P\left(\bigcup_{n=1}^{\infty} C_n\right) \quad (1.3.8)$$

$\{C_n\}$ 을 사건의 감소열이라고 하면

$$\lim_{n \rightarrow \infty} P(C_n) = P(\lim_{n \rightarrow \infty} C_n) = P\left(\bigcap_{n=1}^{\infty} C_n\right) \quad (1.3.9)$$

- 불의 부등식

$$P(\cup_{n=1}^{\infty} C_n) \leq \sum_{n=1}^{\infty} P(C_n)$$

1.4 Conditional Probability and Independence

- 조건부 확률 이용한
 - 확률의 곱셈법칙
 - 총확률의 법칙(배타적이고 전체를 이루는 사건 $A_1, A_2, \dots, A_k$)
- 베이즈 정리
 $P(A_i) > 0$ 인 사건을 $A_1, \dots, A_k$, 표본공간 C의 분할 형성

$$P(A_j|B) = \frac{P(A_j)P(B|A_j)}{\sum P(A_i)P(B|A_i)}$$

↳ 증명 : 조건부확률의 정의, 총확률의 법칙

- 독립성
 - 통계적으로 독립 = 확률적으로 독립 = 확률 개념에서의 독립
 - 쌍으로 독립이라고 해서 서로 독립은 아님
Ex. 사건 3가지 A_1, A_2, A_3 존재
→ 2쌍씩 독립이지만 3쌍이 독립이 아닐 수 있음
 - 독립 실험 : 한 실험 결과에 대한 사건과 다른 실험 결과에 대한 사건이 독립되도록 확률 실험 계속 시행

1.5 Random Variables(확률변수)

- 확률변수 : 표본공간 C에서의 확률실험이 주어졌다면, 표본공간 C의 하나의 원소에 하나의 실수 값을 대응시키는 함수
- X의 공간(space) 또는 범위(range)는 실수의 집합 $D = \{x : x = X(c)\}$ 이다
 - D : 가산형 집합 → 이산형(discrete) 확률변수
 - D : 연속형 집합 → 연속형 확률변수
- Pmf와 Pdf는 서로 상당히 다른 독립체이고, Cdf는 확률변수의 확률분포를 고유하게 결정
 - X와 Y의 cdf가 같다면 “분포가 동일하다”라고 표현, but 동일한 확률변수라고 할 수 없음
- **Cdf의 성질**
 1. 모든 a와 b에 대해 $a < b$ 면 $F(a) \leq F(b)$ 이다(F는 비감소함수)
 2. $\lim_{x \rightarrow -\infty} F(x) = 0$ (F의 하한은 0)
 3. $\lim_{x \rightarrow \infty} F(x) = 1$ (F의 상한은 1)
 4. $\lim_{x \rightarrow x_0} F(x) = F(x_0)$ (F는 오른쪽 연속)

1.6 Discrete Random Variables

- 확률변수의 공간이 유한이거나 셀 수 있는 경우

1.7 Continuous Random Variables

- 확률변수의 cdf가 연속함수이면

1.8 Expectation of a Random Variable

1.9 특수한 기대값

- 분산 : $E[(X - \mu)^2]$
- 적률생성함수 : $M(t) = E(e^{tX})$ *0을 포함하는 개구간에서 존재해야함

1.10 중요한 부등식

- 마르코프 부등식

$$P[u(X) \geq c] \leq \frac{E[u(X)]}{c}$$

↳ 증명 : $E(u(x))$ 전개 → $u(x)=c$ 로 바뀌서

- 체비셰프 부등식

$$P(|X - \mu| \geq k\sigma) \leq \frac{1}{k^2}, P(|X - \mu| < k\sigma) \geq 1 - \frac{1}{k^2}$$

- 부등호 반대로도 성립
- 평균에서 멀리 떨어져 있을 확률을 상한으로 제한하는 부등식

└ 증명 : 마르코프 부등식 이용, $Y=(X-\mu)^2$

- 엔센의 부등식

뛰바머래는거야ㅎ.ㅎ.?

$\epsilon > 0$ 에 대해 $k\sigma = \epsilon$ 을 취함으로써 체비셰프 부등식의 편리한 형태를 얻을 수 있다. 그러면 식 (1.10.2)는 다음과 같이 된다.

$$\text{모든 } \epsilon > 0 \text{에 대해 } P(|X - \mu| \geq \epsilon) \leq \frac{\sigma^2}{\epsilon^2} \quad (1.10.3)$$

이 절의 두 번째 부등식은 볼록함수와 관련되어 있다.

정의 1.10.1

$-\infty \leq a < b \leq \infty$ 일 때 구간 (a, b) 에서 정의된 함수 ϕ 는 (a, b) 안에 있는 모든 x, y 와 모든 $0 < \gamma < 1$ 에 대해 다음과 같으면 볼록(convex)함수라고 한다.

$$\phi[\gamma x + (1 - \gamma)y] \leq \gamma\phi(x) + (1 - \gamma)\phi(y) \quad (1.10.4)$$

만약 위 부등식이 엄격하면 ϕ 를 순볼록(strictly convex)이라고 한다.

ϕ 의 1차 또는 2차 미분 존재 여부에 따라 다음 정리가 증명될 수 있다.

정리 1.10.4

만약 ϕ 가 (a, b) 에서 미분 가능하면

- (a) ϕ 는 모든 $a < x < y < b$ 에 대해 $\phi'(x) \leq \phi'(y)$ 일 때에 한하여 볼록이다.
- (b) ϕ 는 모든 $a < x < y < b$ 에 대해 $\phi'(x) < \phi'(y)$ 일 때에 한하여 순볼록이다.

만약 ϕ 가 (a, b) 에서 두 번 미분 가능하면

- (a) ϕ 는 모든 $a < x < b$ 에 대해 $\phi''(x) \geq 0$ 일 때에 한하여 볼록이다.
- (b) ϕ 는 모든 $a < x < b$ 에 대해 $\phi''(x) > 0$ 이면 순볼록이다.

이 정리의 두 번째 부분은 첫 번째 부분에서 바로 유도된다. 반면에 첫 번째 부분은 직관을 필

요로 하며, 이에 대한 증명은 대부분의 해석학 책에 나와 있다. 예를 들어 Hewitt과 Stromberg (1965)를 참조하라. 매우 유용한 확률 부등식이 볼록성으로부터 유도된다.

정리 1.10.5 [엔센의 부등식]

만약 ϕ 가 개구간 I 에서 볼록이며, X 가 받침이 I 안에 있고 유한 기댓값을 가진 확률변수라면

$$\phi[E(X)] \leq E[\phi(X)] \quad (1.10.5)$$

만약 ϕ 가 순볼록이면 부등식은 X 가 상수 확률변수가 아닌 한 엄격하다.

증명: ϕ 가 2차 미분된다고 가정한다. 그러나 일반적으로는 볼록성만 요구된다. $\phi(x)$ 를 $\mu = E[X]$ 에 대해 2차까지 테일러 급수로 확장하면

$$\phi(x) = \phi(\mu) + \phi'(\mu)(x - \mu) + \frac{\phi''(\zeta)(x - \mu)^2}{2}$$

여기서 ζ 는 x 와 μ ⁹ 사이의 값이다. 위 식에서 오른쪽 끝은 음이 아니므로 다음을 얻는다.

$$\phi(x) \geq \phi(\mu) + \phi'(\mu)(x - \mu)$$

양쪽에 기댓값을 취하면 결과가 도출된다. 이 부등식은 X 가 상수가 아니라고 할 때 모든 $x \in (a, b)$ 에 대해 $\phi''(x) > 0$ 이면 엄격하다.

예제 1.10.3 평균 μ 와 유한 2차 적률을 가진 비퇴화 확률변수를 X 라고 하면 $\mu^2 < E(X^2)$ 이다. 이는 순볼록함수 $\phi(t) = t^2$ 을 이용한 엔센의 부등식(Jensen's inequality)으로부터 구할 수 있다.

- $HM(\text{조화평균}) \leq GM(\text{기하평균}) \leq AM(\text{산술평균})$

- HM(조화평균) : 산술평균의 역수
- GM(기하평균) : 곱의 평균

▼ Chap 2. 다변량 분포

2.1 Distributions of Two Random Variables

- $X=(X_1, X_2)'$
- 결합분포, 주변분포($M_{\{X_1, X_2\}}(t_1, t_2)$)
- $E(X) = [E(X_1) \quad E(X_2)]$

2.2 Transformations: Bivariate Random Variables

- 확률변수 함수의 분포를 구하는 방법
1) 변수변환 2) cdf 3) 적률생성함수 기법

2.3 Conditional Distributions and Expectations

- 조건부 기댓값 $E(u(X_2)|x_1) = \int u(x_2)f_{2|1}(x_2|x_1)dx_2$
- 조건부 분산 $Var(X_2|x_1) = E([X_2 - E(X_2|x_1)]^2|x_1) = E(X_2^2|x_1) - [E(X_2|x_1)]^2$
- $E(E(X_2|X_1)) = E(X_2)$
 $Var(E(X_2|X_1)) \leq Var(X_2)$

2.4 Independent Random Variables

$$f(x_2) = f_{2|1}(x_2|x_1), f(x_1, x_2) = f_1(x_1)f_2(x_2)$$

→ 누적분포함수로도 표현 가능!!

$$\rightarrow E[u(X_1)v(X_2)] = E[u(X_1)]E[v(X_2)]$$

$$\text{ex. } E(X_1, X_2) = E(X_1)E(X_2)$$

$$\rightarrow M(t_1, t_2) = M(t_1, 0)M(0, t_2)$$

2.5 The Correlation Coefficient

- 상관계수로 $E(Y|X)$ 랑 $E(Var(Y|X))$ 나타낼 수 있음

2.6 Extension to Several Random Variables

2.7 Transformations for Several Random Variables

2.8 Linear Combinations of Random Variables

- 독립 + 동일한 분포를 갖는 확률변수의 모음 : 확률표본

▼ Chap 3. 몇가지 특수한 분포(이항, 푸아송, Γ , t , F)

3.1 The Binomial and Related Distributions

- 이항분포 → 다항분포로 일반화

3.2 The Poisson Distribution

$$\sum_{x=0}^{\infty} \frac{z^x}{x!} = e^z$$

- 시간 구간에서 발생하는 특정한 사건의 수

3.3 The Γ , chi-square, and Beta Distributions

- 모두 Γ 분포와 관련된 분포임!

- Γ 분포 : 감마 함수 이용
 - 알파, 베타 값의 다른 값에 대해 다양한 분포 모양
 - $\Gamma(1, \text{beta}) = \text{Beta}(1/\text{beta})$
 - 가법 성질
: $X_i \sim \Gamma(a_i, b)$

$$Y = \sum_{i=1} X_i \sim \Gamma(\sum a_i, b)$$

- 푸아송 분포에서도 자연적으로 발생
- $(0, \infty)$ 인 치우친 분포에서 다양한 모양

- 카이제곱

$$\Gamma\left(\frac{r}{2}, 2\right)$$

- 통계학에서 자주 사용
- Γ 분포의 가법 성질 똑같이 적용

$$X_i \sim \chi^2(r_i), \quad Y = \sum_{i=1} X_i \rightarrow \chi^2(\sum r_i)$$

- 베타분포

- 유계구간 (a, b) 을 받침으로 가진 분포에 대해 다양한 모양 제공
- 감마분포 따르는 두 확률변수 $X(a, 1), Y(b, 1) \rightarrow$

$$\frac{X}{X + Y} \sim \text{Beta}(a, b)$$

3.4 The Normal Distribution

- 위치모수 μ , 척도모수 σ
*척도 모수 : 감마분포의 B, 형상 모수 : 감마분포의 σ , 이항분포의 p, 푸아송분포의 μ
- $X \sim N(\mu, \sigma^2)$ & $\sigma^2 > 0$,

$$\frac{(X - \mu)^2}{\sigma^2} \rightarrow \chi^2(1)$$

- 가장 중요한 성질 : 독립성 하에서 가법성 VV

3.5 The Multivariate Normal Distribution

3.6 t- and F-Distribution

- t분포 : $W \sim N(0, 1), V \sim \chi^2(r)$

$$T = \frac{W}{\sqrt{V}/r}$$

- 자유도가 ∞ 에 가까워지면, $N(0, 1)$ 로 수렴

- 평균 0, 분산 $\frac{r}{r-2}$
- F분포
 - $U, V \sim \chi^2(r)$

$$F = \frac{U/r_1}{V/r_2}$$

- 스튜던트의 정리

$X_1, X_2, \dots, X_n$ 을 각각 평균 μ , 분산 σ^2 인 iid 확률변수라고 하자. 다음 확률변수를 정의하자.

$$\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i, \quad S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$$

그러면 다음이 성립한다.

- (a) $\bar{X}$ 는 $N\left(\mu, \frac{\sigma^2}{n}\right)$ 분포를 따른다.
- (b) $\bar{X}$ 와 S^2 은 서로 독립이다.
- (c) $(n-1)S^2/\sigma^2$ 은 $\chi^2(n-1)$ 분포를 따른다.
- (d) 다음 확률변수는 자유도 $n-1$ 인 스튜던트 t -분포를 따른다.

$$T = \frac{\bar{X} - \mu}{S/\sqrt{n}} \quad (3.6.9)$$

3.7 Mixture Distributions

- 복합 : 분포의 혼합

▼ Chap 05. Consistency and Limiting Distributions

5.1 Consistency and Limiting Distributions

- 확률 수렴 : 확률변수 X_n 이 상수 X 에 수렴

$$\lim P[|X_n - X| \geq \epsilon] = 0$$

⇒ 일치성!

5.2 Convergence in Distribution

- 분포 수렴 #cdf

$$\lim F_{X_n}(x) = F_X(x)$$

- 연속인 점만 가능
- 스텔링 공식..
- 퇴화분포(Degenerate Distribution) : 확률변수가 특정한 하나의 값만을 가질 때의 분포
 - $P(X = a) = 1$
- X_n 이 X 로 확률수렴하면, X_n 은 X 로 분포수렴
- 확률유계/델타방법/적률생성함수 기법 → 분포수렴 확인할 수 있음

5.3 Central Limit Theorem

$$Y_n = \frac{\bar{x} - \mu}{\sigma/\sqrt{n}} \rightarrow dN(0, 1)$$

- Y_n 이 극한표준정규분포를 가진다 = Y_n 이 표준정규확률변수로 분포수렴한다

↳ mgf로 증명

- 이걸로 통계적 추론에 응용

5.4 Extensions to Multivariate Distributions

▼ Chap 04. Elementary Statistical Inferences

- 통계량 : 표본의 함수
 - 점추정량
 - 불편성 만족
 - T를 점추정량, t를 점추정값
 - 신뢰구간
 - θ 를 포함할 확률이 $1-\alpha$
 - 순서통계량
 - 몇가지 성질이 확률표본을 얻은 분포에 의존하지 않기 때문
 - 그 자체로도 중요 : 표본범위, 중앙값 같은 거 편하게 구할 수 있
- q-q plot
- 이항분포는 이산성 때문에 중앙값에 대한 신뢰구간에서 단지 특정 신뢰수준만 가능
 - 검정 오류

결정	본질의 참상태	
	H_0 이 참	H_1 이 참
H_0 기각	1종 오류	올바른 결정
H_0 채택	올바른 결정	2종 오류

- 검정력을 최소화 한다 = 2종 오류의 확률을 최소화한다
- 유의수준 α = 1종 오류를 범할 확률의 최댓값 = H_0 이 참일 때 검정의 검정력 최댓값
- 카이제곱검정
 - 적합도 검정
 - 독립성 검정
- 몬테카를로 검정 & 부트스트랩 절차
 - 비모수적 방법
 - *비모수적 방법 : 특정 분포 가정 X
 - *모수적 방법 : 특정 분포(ex.정규분포) 가정, t-검정, ANOVA
 - 데이터의 분포가 알려지지 않은 경우에도 유용하게 사용

▼ Chap 06. Maximum Likelihood Methods

6.1 Maximum Likelihood Estimation

- 우도함수
$$L(\theta) = \prod f(x_i; \theta)$$
 - 로그는 일대일함수라 $l(\theta)$ 써도 정보의 손실
- mle를 고려하는 것의 이론적 타당성
 - **점근적으로 참값 θ_0 에서 우도함수가 최대가 된다. ⇒ 일치성!**

$$\lim_{n \rightarrow \infty} P_{\theta_0}[L(\theta_0, X) > L(\theta, X)] = 1$$

↳ 표본이 많아질수록 θ 에서의 우도는 작아져 참 모형과 다른 모형이 점점 더 명확히 분리된다는 의미

- mle가 존재하는지, 만약 존재한다면 유일한지에 대한 보장은 없다.

6.2 Rao-Cramer Lower Bound and Efficiency

6.3 Maximum Likelihood Tests

- LRT(우도비검정)
 - $H_0 : \theta = \theta_0 \quad H_1 : \theta \neq \theta_0$

$$\Lambda = \frac{L(\theta_0)}{L(\theta)}, -2\log\Lambda \xrightarrow{d} \chi^2(1)$$

- 왈드형 검정
- 스코어형 검정

6.4 Multiparameter Case: Estimation

6.5 Multiparameter Case: Testing

6.6 The EM Algorithm

▼ Chap 07. Sufficiency

7.1 Measures of Quality of Estimators

- 다양한 통계적 추론에 특정 통계량이 왜 사용되는지에 대해 설명

① 일치성 : Y_n 확률적으로 θ 에 수렴 $\rightarrow Y_n$ 일치추정량

② 불편성 : $E(Y_n) = \theta$

↳ 둘 다 불편추정량이라면, 분산 작은 거

⇒ **최소분산불편추정량!(MVUE)**

- 결정 규칙 : 최악의 경우에서도 **손실 함수**가 최소화
 - E(손실함수)=위험함수
 - 최소최대기준에 따라 최선의 결정 함수 구함
 - 위험함수를 최소화하는 결정함수 = 최소평균제곱오차추정량

7.2 A Sufficient Statistic for a Parameter, 7.3 Properties of a Sufficient Statistic

- **충분통계량..**
 - 모수에 대한 정보를 모두 확보하고 있다는 의미
 - 충분통계량이 주어졌을 때 확률 변수의 조건부 확률이 모수에 의존X
 - 네이만의 인수분해 정리 이용

$$f(X | \theta) = g(T(X), \theta) \cdot h(X),$$

-g(T(X),θ): T(X)와 θ의 함수, h(X): θ와 독립적인 함수

- 유일하지 않음
- 라오-블랙웰 :

Y1 : 충분통계량, Y2 : 불편추정량

$E(Y_2|Y_1)$ 이 충분 통계량, 불편추정량, Y2보다 분산 작음

충분통계량하면서, 불편추정량인 경우 최소분산 비편향추정량의 후보가 될 수 있다는 것입니다.

모수에 대한 최소분산 불편추정량을 찾는 경우, 그 모수에 대한 충분 통계량이 존재하면 그 충분통계량의 함수로 제한하여 찾아야 한다

- mle는 점근적으로 θ 의 불편추정량

7.4 Completeness and Uniqueness

- 완비성

- 통계량이 가진 정보가 부족하지 않다는 의미.

$$E[g(T(X))] = 0 \text{ for all } \theta \in \Theta \implies P(g(T(X)) = 0) = 1$$

- $T(X)T(X)T(X)$ 가 가지고 있는 정보로는 $g(T(X))g(T(X))g(T(X))$ 를 "추가적으로 설명할 여지가 없다"는 뜻

- $E(u(Z))=0$ 은 확률이 0인 점의 집합을 제외하고, $u(y_1)=0$

- 레만-세페 정리

: $Y_1 = u_1(X_1, \dots, X_n)$ θ 에 대한 충분통계량 & 확률밀도함수의 족 $[F_{y_1}(Y_1; \theta)]$ 이 완비

→ θ 의 불편추정량 y_1 이 존재한다면 그 함수의 θ 의 유일한 최소분산추정량

- ex

균등분포 $U[0, \theta]$ 에서:

1. $Y_n = \max\{X_1, \dots, X_n\}$ 는 θ 에 대한 충분통계량이고, 완비임.
2. $E[Y_n] = \frac{n}{n+1}\theta$ 이므로, $\frac{n+1}{n}Y_n$ 은 θ 의 불편추정량.
3. Y_n 이 완비 충분통계량이므로 $\frac{n+1}{n}Y_n$ 은 최소분산불편추정량(MVUE).

7.5 The Exponential Class of Distributions

- 즉시 결정되는 완비충분통계량을 갖는다
- 확률밀도함수 형태 → 지수족 판단

$$f(x; \theta) = \exp[p(\theta)K(x) + H(x) + q(\theta)]$$

- 지수족에 속하는 유명한 확률 밀도함수가 많습니다. (베르누이, 이항분포, 포아송분포, 지수분포, 기하분포, 정규분포, 균등분포, 감마분포 등등)

- 지수류가 정칙 → $Y_1 = \sum_{i=1}^n K(X_i)$ 가 θ 에 대한 완비충분통계량

1. 알려진 σ^2 에 대해 $N(\theta, \sigma^2)$ 에서 θ 의 mle $\theta_{\text{hat}} = \bar{x}$ 는 θ 에 대한 최소충분통계량이다.

2. 평균 θ 인 푸아송 분포에서 θ 의 mle $\theta_{\text{hat}} = \bar{x}$ 또는 θ 에 대한 최소충분통계량이다.

3. 구간 $(0, 8)$ 의 균등분포에서 θ 의 mle $\theta_{\text{hat}} = \max(X_i)$ 는 θ 에 대한 최소충분통계량이다.

4. $N(\theta_1, \theta_2)$ 에서 $\theta_1 = \bar{x}, \theta_2 = \frac{(n-1)}{n}S^2$ 은 결합 최소충분통계량이다.

- 보조통계량 모수에 의존하지 않는 분포, 모수에 대한 어떤 정보도 갖고 있지 않는 것처럼 보인다: ex. 위치불변통계량, 규모불변통계량, 위치규모불변통계량

▼ Chap 08. Optimal Tests of Hypotheses

8.1 Most Powerful Tests

- 2종 오류는 검정력 함수를 이용하여 계산하는 $(1-\beta)$ 를 최대화
- 우도 함수의 비율 이용
- 단순 가설 간 검정 ($H_0 : \theta = \theta_0$ vs $H_1 : \theta = \theta_1$)에서만 직접적으로 적용
- 불편 검정이란 우리가 설정한 1종 오류의 확률($=\alpha$)보다 검정력의 확률($=1-\beta$)이 높은 상태

8.2 Uniformly Most Powerful Tests

- 유의수준 α 에서 대립가설 전체에 대해 검정력이 가장 높은 검정
- 최강력 검정(Most Powerful Test)의 일반화된 형태 → **복합 가설(단측 대립 가설)**의 검정
- 귀무가설 H_0 아래 유의수준 조건을 만족하면서 대립가설 H_1 전체에 대해 검정력이 균등하게 가장 높은 검정
- 우도비(Likelihood Ratio Test)를 사용해 최강력 검정을 구한 뒤, 이를 H_1 의 모든 $\mu > \mu_0$ 에 대해 적용

8.3 Likelihood Ratio Tests

- 평균 검정
 - 타당성에 대한 견고성 O, 검정력에 대한 견고성 X
 - 정규성 가정, t분포 사용
- 분산 검정