

[Basic] 회귀 분석

▼ Chap 1. Linear Regression with One Variable

- X와 Y의 관계를 함수적으로 표현
- 최소 제곱법 : Minimize $Q(b_0, b_1) = \sum (Y_i - (b_1 * X_i + b_0))^2$
 - b_0 : x=0일 때, 준비해야할 평균 변화
 - b_1 : x가 한 단위 증가할 때 평균 증가
 - Q를 최소화하는 값을 미분하여 b_0, b_1 값 도출
 - 정규 방정식 이용
 - ↳ 통계학에서 선형 회귀상에서 알지 못하는 값을 예측하기 위한 방법론
 - ↳ 다항 방정식을 행렬로 나타내고, 역행렬을 통해 최적의 값을 찾는 방법
- Q 미분 = 0이 되는 b_0, b_1 찾기
- Gauss Markov Theorem : Under the conditions of regression model (1), the least squares estimators b_0 and b_1 are unbiased and have minimum variance among all unbiased linear estimators
- Residual : $e_i = Y_i - \hat{Y}_i$
- Estimation of Variance
- Normal Error Regression model

Simple linear regression model과의 차이점은??

- **Likelihood**
 - 관측된 사건이 고정된 상태에서, 확률 분포가 변화될 때(=확률 분포를 모를 때 = 가정할 때), 확률
 - The probability of the observed data considered as a function of unknown parameters. Numerical quantity to express the order of preferences on unknown parameters.

⇒ Maximum Likelihood

LSE와의 차이점..

▼ Chap 2. Inferences in Regression and Correlation Analysis

- Statistical Inference : critical value나 p-value로 검정
- Inference concerning β_1, β_0
 - 신뢰구간 : $b_1 \pm t(1 - \frac{\alpha}{2}) * s(b_1)$
 - t(n-2)로 검정
- Prediction of New Obs
 - 변동성과 불확실성 더 크게 포함
 - Different!(분포의 평균 예측 = Y가 어떤 경향성을 보이는지에 대한 전반적인 이해와 예측임)
 - 신뢰구간에 z 분포 사용
 - 이 때 분산은 $\sigma^2(pred) = \sigma^2(Y_{h(new)} - \hat{Y}_h) \Rightarrow$ 새로운 관측값에 대한 불확실성을 평가 위해
- **ANOVA 드려 나왔다 아노바...**

- 기본 개념 : “전체 변동량(SSTO)을 모델로 설명되는 변동량(SSR)과 잔차 변동량(SSE)로 분할하는 것”

- SSTO(전체 변동량, Total Sum of Squares) : 데이터가 전체 평균과 얼마나 멀리 떨어져있는지
→ 전체 데이터 집합 내 변동성

$$*\varepsilon_i = Y_i - E(Y_i), \text{ unknown true error}$$

$$SSTO = \sum (y_i - \bar{y})^2, \text{ df} = n-1$$

- SSR(Regression Sum of Square) : 회귀 모델로 설명되는 변동량, 클수록 좋음 !

$$SSR = \sum (\hat{y}_i - \bar{y})^2, \text{ df} = 1$$

- SSE(Error Sum of Square) : 잔차 변동

$$*e_i = Y_i - \hat{Y}_i, \text{ observed error}$$

$$SSE = \sum (y_i - \hat{y}_i)^2, \text{ df} = n-2$$

$$\Rightarrow SSTO = SSR + SSE !$$

- ANOVA table for simple linear regression

-F test, $F = MSR/MSE$

- $\beta_0 = 0$ 임을 검정
 - t 검정
 - ANOVA
 - General Linear Test : compare error sums of two models, F 검정

- **Linear Association 결정계수**

$$R^2 = \frac{SSR}{SSTO} = 1 - \frac{SSE}{SSTO}$$

▼ Chap 3. Diagnostics and Remedial Measures(예측변수, 잔차)

- Model assumptions
 - linearity : 선형 회귀의 경우, 잔차 분석(잔차가 랜덤하게 분포하는지)
 - homogeneity : 일정한 분산
 - independence : 데이터가 자기상관 없어야 함
 - normality : 모델의 오차 정규 분포, Q-Q plot
- Residual(observed error), $e_i = Y_i - \hat{Y}_i$,

- $E(e_i) = 0$
- $Var(e_i) = MSE$
- But,, NOT independent

⇒ 잔차 분석을 통해 모델 가정이 위배되는지 확인해야함

(회귀함수 선형, 오차 등분산성, 이상치, 독립성, 정규 분포, 중요한 예측 변수)

→ residual plot

→ normal probability plot or q-q plot

- Tests for Homogenous Variance
 - Brown-Forsythe Test(그룹의 중앙값 이용)
 - Breusch-Pagan Test
- 위배된다면, transformation

-Transformation of X, not of Y. Why? 오차항의 분포 변화시킬 가능성

-선형성, 독립성 만족한다면 → Y transformation

ex. Box-Cox transformation : 어떤 Y의 변환이 가장 적절한가를 자동으로 찾는 방법

- F Test for Lack of Fit
 - SSE의 차이 이용
 - c : X의 개수, i : 반복되는 관측 값을 포함한 총 관측 값의 수

▼ Chap 5. Matrix Approach to Simple Linear Regression

- matrix
$$\begin{bmatrix} 1 & X_1 \\ 1 & X_2 \\ 1 & X_3 \end{bmatrix} \begin{bmatrix} \beta_0 \\ \beta_1 \end{bmatrix} = \begin{bmatrix} \beta_0 + \beta_1 X_1 \\ \beta_0 + \beta_1 X_2 \\ \beta_0 + \beta_1 X_3 \end{bmatrix}$$
- linearly dependent
 - column vector 들을 조합하여 0 벡터를 만들 수 있다면 그것도
- rank : Maximum number of linearly independent columns
- matrix approach to SLR
..내 머리아프다

▼ Chap 6. Multiple Regression-1

- 2차 regression, interaction effects, ...
- The term "linear model" refers to the fact that model is **linear in the parameters**(like B0, B1,...).
- Matrix Form
- ANOVA results(모델 전체에 대한, 특정 회귀계수는 t검정으로)
$$F^* = \frac{MSR}{MSE} \sim F(p-1, n-p) \text{ under } H_0$$
- Adjusted R^2 : 독립 변수의 수가 늘어나면 자동으로 증가하는 경향
- Inference concerning β_k
 - 신뢰구간 : $b_k \pm t(1 - \frac{\alpha}{2}) * s(b_k)$
 - t(n-p)로 검정 ;Chap 2. SLR이랑 똑같고 자유도만 바뀜
- Mean response ↔ new prediction : 분산이 달라지능 거

▼ Chap 7. Multiple Regression-2

- Extra sum of squares
 - SSE when predictor variables are added to the model
 - $SSR(X_2|X_1) = SSE(X_1) - SSE(X_1, X_2)$
 - $SSTO = SSR(X_1) + SSE(X_1)$
$$= SSR(X_1) + SSR(X_2|X_1) + SSE(X_1, X_2)$$
$$= X_1\text{이 이미 설명한 변동} + X_1 \text{ 있는 상태에서 } X_2\text{가 설명하는 변동} + SSE$$
$$SSR(X_1, X_2) = SSR(X_1) + SSR(X_2|X_1) \Rightarrow \text{수식이 정리돼서 F 검정도 가능함(원래 t검정)}$$
 - B_k에 대한 검정
 - t 검정, F 검정
 - 효과 0인지 아닌지가 아니라 B_1 = B_2인지 알고 싶다면

- 부분 결정계수도 있음!
- Standardized multiple regression : 다른 단위와 범위를 가진 변수들을 동일하게 변환
- multicollinearity
 - uncorrelated 하다면
 - : 부분 결정계수 = 0 (ex) $SSR(X1|X2) = SSR(X1)$
 - Centering으로 avoid 할 수 있음

▼ Chap 8. Regression Models for Quantitative and Qualitative Predictors

- polynomial regression : 2차 함수 형태 등등..
- Interaction regression models
- Qualitative predictors
 - (n-1)개의 dummy 변수
 - 함수 그래프 → parallel
- Interaction btw Quantitative and Qualitative predictors

▼ Chap 9. Model Selection and Validation

- Criteria for Model Selection
 - all predictors necessary?
 - $SSE_p, R^2,$
 - Mallows' C_p
 - **AIC_p**
 - predictor 개수에 페널티
 - 근데 이게 likelihood 함수랑 관련 있나본데
 - $Press_p$ (prediction sum of squares)
- Automatic Search procedures for model selection
 - Stepwise regression methods
 - Forward Stepwise selection
 - Backward selection
- Model validation